UNIVERSITAS AIRLANGGA
FAKULTAS VOKASI
PROGRAM STUDI D4 TEKNIK INFORMATIKA
LAPORAN PRAKTIKUM PEMBELAJARAN MESIN
PERTEMUAN 8

Klasifikasi Naïve Bayes, Support Vector Machine (SVM), dan Decision Tree pada Dataset Online Shoppers Purchasing Intention Serta Implementasi Antarmuka Streamlit

---

Mata Kuliah / SKS	: Praktikum Pembelajaran Mesin (1 SKS)
Dosen Pengampu	: Dr. Indah Werdiningsih, S.Si., M.Kom Barry Nuqoba, S.Si., M.Kom., Ph.D Purbandini, S.Si., M.Kom
Nama Mahasiswa / Kelompok	: [NAMA MAHASISWA / KELOMPOK - Silakan disesuaikan]
NIM	: [NIM MAHASISWA - Silakan disesuaikan]
Semester / Tahun Akademik	: Semester 5 (Ganjil) / 2026-2027

1. TUJUAN PRAKTIKUM

- Mampu memahami teori dan mengimplementasikan algoritma klasifikasi Naïve Bayes (GaussianNB) dan Support Vector Machine (SVM/SVC) menggunakan pustaka Scikit-Learn pada bahasa pemrograman Python.
- Mampu memproses dataset nyata (Online Shoppers Purchasing Intention) melalui tahapan preprocessing yang bersih, mencakup penanganan nilai kosong (missing values), penghapusan data duplikat, dan deteksi nilai pencilan (outliers).
- Mampu menangani ketidakseimbangan kelas target (imbalanced data) menggunakan metode SMOTENC (oversampling) dan RandomUnderSampler (undersampling) secara terisolasi pada data training tanpa menimbulkan kebocoran data (data leakage).
- Mampu membandingkan kinerja model Decision Tree (hasil baseline UTS), Gaussian Naïve Bayes, dan Support Vector Machine RBF berdasarkan Confusion Matrix serta metrik evaluasi Accuracy, Precision, Recall, dan F1-Score.
- Mampu menganalisis komparasi kinerja secara adil (apples-to-apples) dengan pembagian data uji yang identik (80% training dan 20% testing).
- Mampu mengintegrasikan model klasifikasi dengan performa terbaik ke dalam aplikasi antarmuka pengguna interaktif (UI/UX) berbasis Streamlit untuk memprediksi niat belanja pengunjung website secara langsung.

2. DESKRIPSI DATASET ONLINE SHOPPERS PURCHASING INTENTION

Dataset yang digunakan dalam praktikum ini adalah Online Shoppers Purchasing Intention (file: online_shoppers_intention.csv). Dataset ini merekam sesi kunjungan pengguna pada situs web e-commerce selama periode satu tahun untuk memprediksi apakah suatu sesi kunjungan akan berakhir dengan transaksi pembelian (Revenue = True) atau tidak menghasilkan pembelian (Revenue = False).

Dataset terdiri dari 12.330 baris data dan 18 kolom (17 fitur prediktor dan 1 variabel target). Karakteristik target Revenue menunjukkan ketidakseimbangan kelas yang signifikan, dengan proporsi awal sebagai berikut:

- Kelas False (Tidak Beli) : 10.422 sampel (84,53%)
  Kelas True (Membeli) : 1.908 sampel (15,47%)
  Rasio Ketimpangan Kelas : ~ 5,46 : 1

Nama Fitur	Tipe Data	Deskripsi & Rentang Nilai
Administrative	Numerik (int64)	Jumlah halaman akun/administratif yang dibuka (0 - 27)
Administrative_Duration	Numerik (float64)	Total waktu (detik) pada halaman administratif (0 - 3398.75)
Informational	Numerik (int64)	Jumlah halaman informasi/kontak yang dikunjungi (0 - 24)
Informational_Duration	Numerik (float64)	Total waktu (detik) pada halaman informasi (0 - 2549.38)
ProductRelated	Numerik (int64)	Jumlah halaman katalog produk yang dikunjungi (0 - 705)
ProductRelated_Duration	Numerik (float64)	Total waktu (detik) melihat katalog produk (0 - 63973.52)
BounceRates	Numerik (float64)	Persentase sesi yang langsung keluar tanpa interaksi (0.0 - 0.2)
ExitRates	Numerik (float64)	Persentase halaman yang menjadi akhir sesi pengunjung (0.0 - 0.2)
PageValues	Numerik (float64)	Rata-rata kontribusi halaman terhadap transaksi e-commerce (0.0 - 361.76)
SpecialDay	Numerik (float64)	Kedekatan tanggal kunjungan dengan hari perayaan khusus (0.0 - 1.0)
OperatingSystems	Numerik Kategori (int64)	Kode sistem operasi perangkat pengguna (1 - 8)
Browser	Numerik Kategori (int64)	Kode peramban web yang digunakan (1 - 13)
Region	Numerik Kategori (int64)	Kode wilayah geografis pengunjung (1 - 9)
TrafficType	Numerik Kategori (int64)	Kode sumber lalu lintas pengunjung (1 - 20)
Month	Kategorikal (object)	Bulan kunjungan ('Feb', 'Mar', 'May', 'June', 'Jul', 'Aug', 'Sep', 'Oct', 'Nov', 'Dec')
VisitorType	Kategorikal (object)	Tipe pengunjung ('Returning_Visitor', 'New_Visitor', 'Other')
Weekend	Kategorikal (bool)	Indikator apakah sesi berlangsung di akhir pekan (False /

		True)
Revenue (Target)	Boolean (bool)	Status transaksi pembelian akhir: True (Membeli), False (Tidak Beli)

3. TAHAPAN PREPROCESSING DAN TRANSFORMASI DATA

Mengikuti tahapan baku pada praktikum dan evaluasi UTS, preprocessing dilakukan secara terstruktur untuk menjamin kebersihan data tanpa data leakage:

- **Pemeriksaan Missing Value:** Dataset diperiksa menggunakan df.isna().sum(). Hasilnya menunjukkan tidak ada nilai kosong (missing values = 0) pada seluruh 18 kolom.
- **Pemeriksaan dan Pembersihan Data Duplikat:** Ditemukan sebanyak 125 baris duplikat identik. Seluruh baris duplikat ini dihapus menggunakan df.drop_duplicates(), sehingga jumlah data bersih yang digunakan adalah 12.205 baris.
- **Deteksi Nilai Pencilan (Outliers):** Deteksi outlier dilakukan pada kolom numerik menggunakan metode Interquartile Range (IQR = Q3 - Q1, batas bawah = Q1 - 1.5*IQR, batas atas = Q3 + 1.5*IQR). Hasil deteksi menemukan adanya outlier pada fitur durasi dan PageValues. Sesuai kesepakatan UTS, outlier dipertahankan (tidak dibuang) karena merepresentasikan perilaku belanja nyata pengunjung yang memiliki durasi browsing tinggi atau nilai transaksi besar.
- **Pemisahan Fitur dan Target:** Data bersih dipisahkan menjadi matriks fitur X (17 fitur) dan vektor label target y (Revenue).
- **Pembagian Data Train-Test (80:20):** Data dibagi menjadi 80% data training (9.764 baris) dan 20% data testing (2.441 baris) menggunakan train_test_split dengan random_state=42 dan parameter stratify=y untuk mempertahankan rasio kelas target yang seimbang antara train dan test.

> **Prinsip Bebas Data Leakage:** Seluruh proses fitting transformer (StandardScaler dan OneHotEncoder) serta resampling HANYA dilakukan pada data training. Data testing (2.441 baris) disimpan dalam kondisi aslinya dan hanya ditransformasikan secara pasif menggunakan transformer yang telah di-fit pada data training. Hal ini menjamin 100% tidak terjadinya kebocoran informasi (data leakage) dari data uji ke model.

Potongan kode preprocessing (src/data_preprocessing.py):

```
def preprocess_data(df):
    # 1. Check and handle missing values
    missing = df.isna().sum().sum()
    if missing > 0:
        df = df.dropna().copy()

    # 2. Check and handle duplicates
    duplicates = df.duplicated().sum()
    if duplicates > 0:
        df = df.drop_duplicates().copy()

    # 3. Detect outliers with IQR (outliers retained)
    ...
```

```
    # 4. Separate features and target
    X = df.drop(columns=['Revenue'])
    y = df['Revenue']
    return X, y
```

Potongan kode transformasi fitur (src/data_transformation.py):

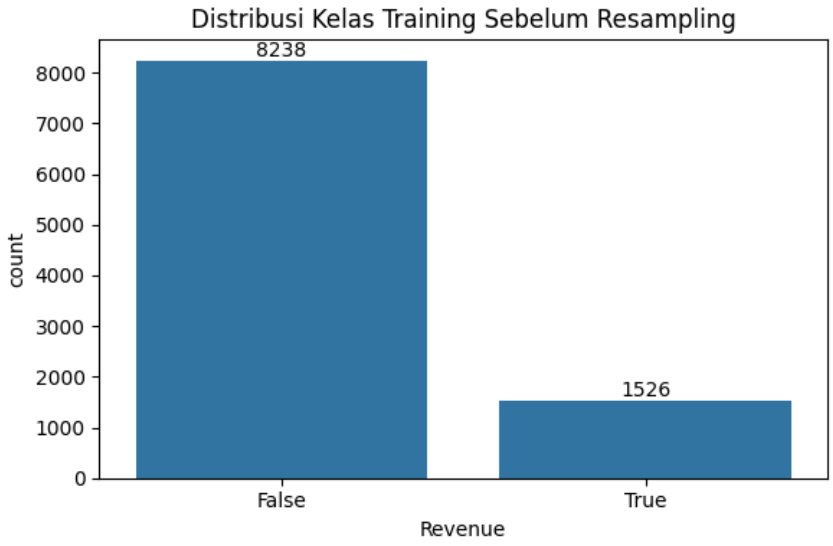
```
def get_preprocessor(X):
    num_cols = X.select_dtypes(include=[np.number]).columns.tolist()
    cat_cols = X.select_dtypes(exclude=[np.number]).columns.tolist()

    preprocessor = ColumnTransformer(
        transformers=[
            ('num', StandardScaler(), num_cols),
            ('cat', OneHotEncoder(handle_unknown='ignore', drop='first'), cat_cols)
        ]
    )
    return preprocessor, num_cols, cat_cols
```

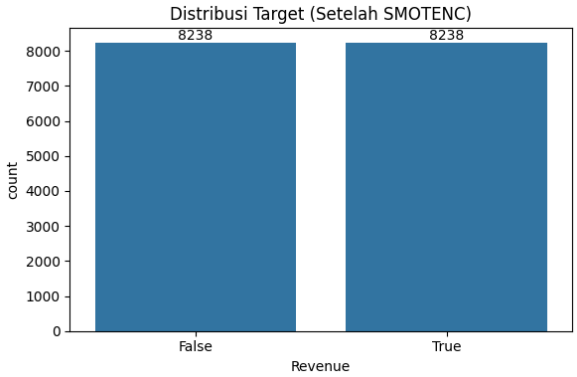
4. PENANGANAN KETIDAKSEIMBANGAN KELAS (RESAMPLING)

Pada data training sebanyak 9.764 sampel, kelas mayoritas False berjumlah 8.238 baris (84,37%) dan kelas minoritas True hanya berjumlah 1.526 baris (15,63%). Jika model dilatih langsung pada data yang sangat tidak seimbang, model cenderung memprioritaskan akurasi pada kelas mayoritas dan mengabaikan kelas minoritas (pembeli). Oleh karena itu, diimplementasikan dua teknik resampling pada data training:

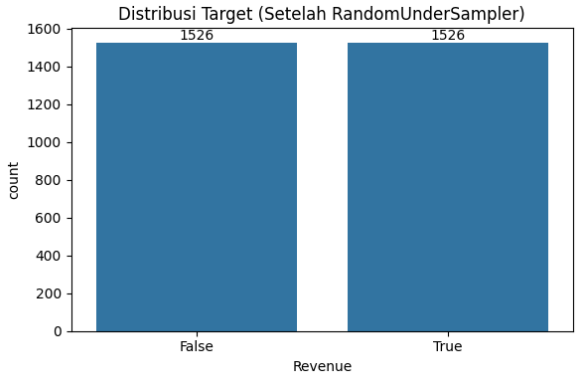
- **1. SMOTENC (Synthetic Minority Over-sampling Technique for Nominal and Continuous):** Metode oversampling khusus untuk dataset dengan fitur campuran. SMOTENC menginterpolasi fitur numerik di antara tetangga terdekat (k-NN), sementara fitur kategorikal (Month, VisitorType, Weekend) ditentukan berdasarkan modus (kategori terbanyak) dari tetangga terdekatnya. Dengan menerapkan SMOTENC SEBELUM OneHotEncoder, data sintetis yang dihasilkan tetap mempertahankan nilai kategori valid dan tidak menghasilkan nilai dummy pecahan. Hasil SMOTENC menyeimbangkan kelas training menjadi 8.238 False dan 8.238 True (total 16.476 sampel).
- **2. RandomUnderSampler (RUS):**
  Metode undersampling yang secara acak memangkas sampel dari kelas mayoritas False agar jumlahnya sama dengan kelas minoritas True. Hasil RandomUnderSampler menghasilkan data training seimbang dengan 1.526 False dan 1.526 True (total 3.052 sampel).



Gambar 1: Distribusi Kelas Data Training Sebelum Resampling (Ketidakseimbangan Rasio ~5.4 : 1)



Gambar 2a: Distribusi Training Setelah SMOTENC (16.476 sampel)



Gambar 2b: Distribusi Training Setelah RandomUnderSampler (3.052 sampel)

5. METODE KLASIFIKASI (DECISION TREE, NAÏVE BAYES, DAN SVM)

A. Decision Tree Classifier (Baseline UTS)

Decision Tree membangun model klasifikasi berbentuk pohon keputusan dengan mempartisi ruang fitur berdasarkan aturan keputusan sederhana. Pada eksperimen ini, parameter yang digunakan sesuai UTS adalah max_depth=10 dan random_state=42. Pembatasan kedalaman pohon dilakukan untuk menghindari overfitting pada data training.

B. Gaussian Naïve Bayes (Pertemuan 8)

Naïve Bayes didasarkan pada Teorema Bayes dengan asumsi 'naif' bahwa semua fitur bersifat saling bebas (conditional independence) jika diberikan label kelas. Karena fitur input telah distandardisasi menjadi distribusi kontinu, model mengasumsikan setiap fitur berdistribusi normal (Gaussian). Parameter

var_smoothing=1e-9 digunakan untuk menambahkan porsi variansi terbesar agar estimasi probabilitas numerik tetap stabil.

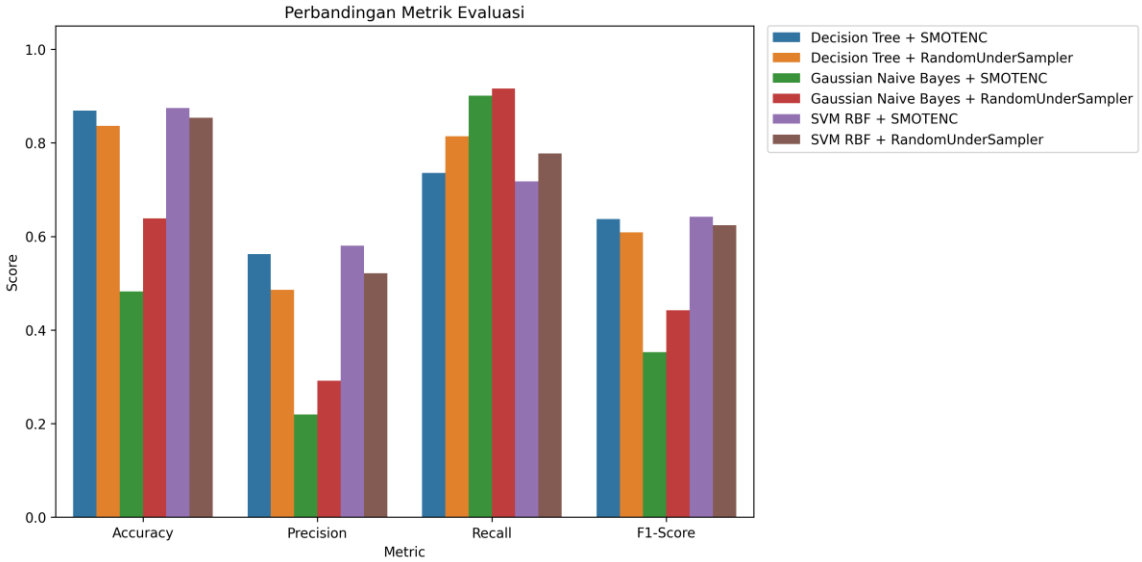
C. Support Vector Machine / SVM RBF (Pertemuan 8)

SVM mencari bidang pemisah (hyperplane) optimal yang memaksimalkan jarak margin antara dua kelas data. Karena hubungan antar fitur pengunjung e-commerce bersifat non-linear dan kompleks, digunakan kernel Radial Basis Function (RBF). SVM sangat diuntungkan oleh tahapan StandardScaler karena algoritma margin sensitif terhadap skala fitur. Parameter yang digunakan adalah C=1.0, random_state=42, dan probability=True untuk mengaktifkan estimasi probabilitas Platt Scaling.

6. HASIL EVALUASI AKTUAL DAN ANALISIS KOMPARASI

Seluruh eksperimen dievaluasi pada data testing yang persis sama sebanyak 2.441 sampel (2.059 False dan 382 True). Metrik dihitung dengan menetapkan kelas Revenue = True (pembeli) sebagai target positif (pos_label=True). Tabel berikut menyajikan hasil evaluasi aktual dari eksekusi program terpadu:

Model & Resampling	Accuracy	Precision	Recall	F1-Score
Decision Tree + SMOTENC	86,89%	56,20%	73,56%	63,72%
Decision Tree + RandomUnderSampler	83,61%	48,59%	81,41%	60,86%
Gaussian Naive Bayes + SMOTENC	48,26%	21,92%	90,05%	35,26%
Gaussian Naive Bayes + RandomUnderSampler	63,87%	29,17%	91,62%	44,25%
SVM RBF + SMOTENC (Terpilih ★)	**87,46%**	**58,05%**	**71,73%**	**64,17%**
SVM RBF + RandomUnderSampler	85,33%	52,11%	77,75%	62,40%



Gambar 3: Grafik Batang Perbandingan Metrik Evaluasi 6 Kombinasi Model

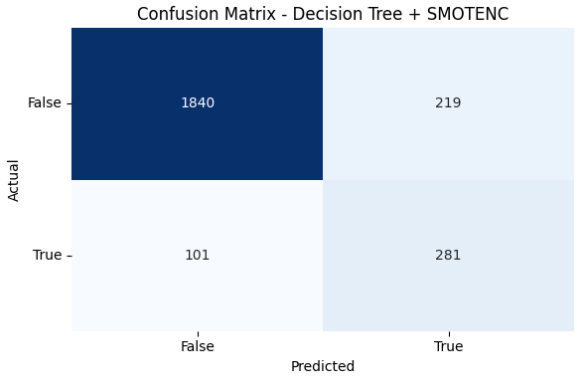
7. ANALISIS CONFUSION MATRIX DAN PEMBAHASAN TP, TN, FP, FN

Confusion Matrix memetakan prediksi model terhadap kondisi aktual pada data testing (2.059 kelas False dan 382 kelas True). Struktur matriks konfusi menggunakan urutan baris [Aktual False, Aktual True] dan kolom [Prediksi False, Prediksi True]:

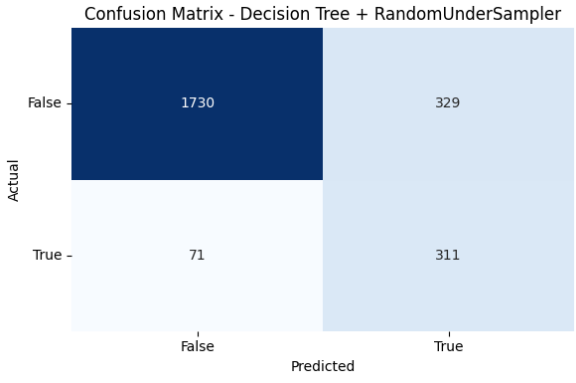
- **True Positive (TP):** Pengunjung yang diprediksi membeli (True) dan secara aktual memang membeli.
- **True Negative (TN):** Pengunjung yang diprediksi tidak membeli (False) dan secara aktual memang tidak membeli.
- **False Positive (FP):** Pengunjung yang diprediksi membeli (True) padahal sebenarnya tidak membeli (False Alarm). Kesalahan ini berpotensi membuang biaya pemasaran atau penawaran diskon yang sia-sia.
- **False Negative (FN):** Pengunjung yang diprediksi tidak membeli (False) padahal sebenarnya membeli (Missed Opportunity). Kesalahan ini menyebabkan e-commerce kehilangan kesempatan mendorong transaksi.

Tabel Rincian Elemen Confusion Matrix Aktual 6 Model:

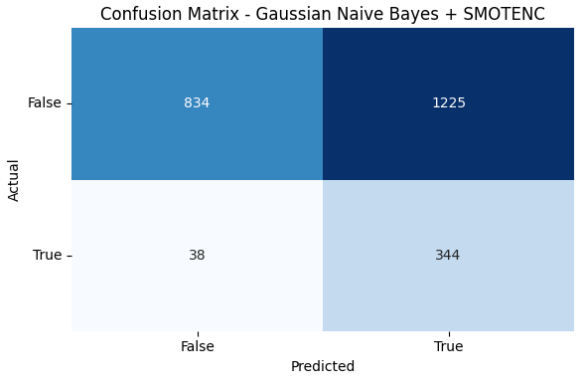
Model & Resampling	TN	FP	FN	TP
Decision Tree + SMOTENC	1.840	219	101	281
Decision Tree + RandomUnderSampler	1.730	329	71	311
Gaussian Naive Bayes + SMOTENC	834	1.225	38	344
Gaussian Naive Bayes + RandomUnderSampler	1.209	850	32	350
SVM RBF + SMOTENC (Terpilih ★)	**1.861**	**198**	**108**	**274**
SVM RBF + RandomUnderSampler	1.786	273	85	297



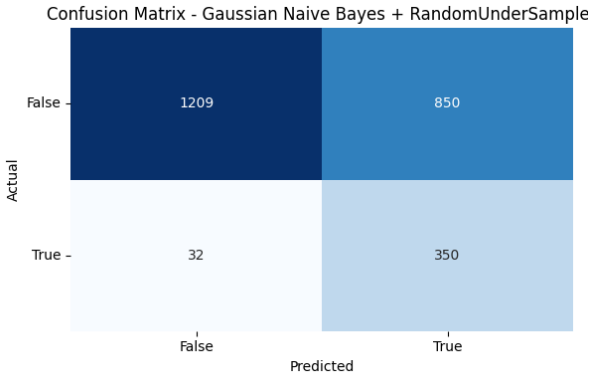
Gambar 4a: Confusion Matrix Decision Tree + SMOTENC



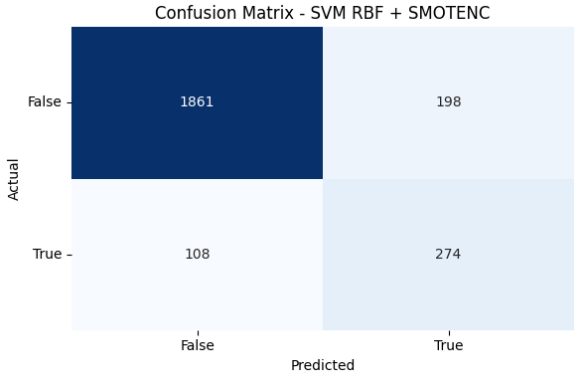
Gambar 4b: Confusion Matrix Decision Tree + RUS



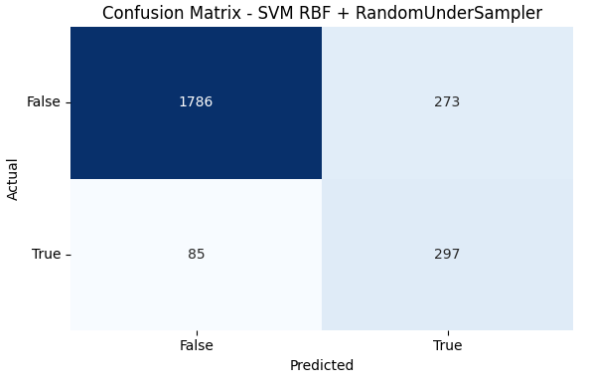
Gambar 4c: Confusion Matrix Naïve Bayes + SMOTENC



Gambar 4d: Confusion Matrix Naïve Bayes + RUS



Gambar 4e: Confusion Matrix SVM RBF + SMOTENC



Gambar 4f: Confusion Matrix SVM RBF + RUS

Pembahasan Perbandingan Metrik & Karakteristik Algoritma

1. Mengapa Akurasi Tinggi Saja Tidak Cukup?
Pada dataset imbalanced dengan proporsi mayoritas 84,53% (False), sebuah model 'dummy' yang selalu menebak False akan dengan mudah meraih akurasi 84,53%. Namun, model tersebut tidak memiliki kemampuan sama sekali untuk mendeteksi pembeli (Recall = 0% dan F1-Score = 0%). Oleh karena itu, metrik Precision, Recall, dan F1-Score pada kelas True adalah tolok ukur esensial dalam mengevaluasi efektivitas model klasifikasi ini.

2. Anomali Kinerja Gaussian Naïve Bayes:
Meskipun Naïve Bayes mencatat Recall yang sangat tinggi (>90%), akurasi dan presisinya anjlok drastis (akurasi hanya 48,26% pada SMOTENC dan 63,87% pada RUS). Hal ini disebabkan oleh pelanggaran asumsi independensi fitur (conditional independence). Fitur-fitur web analytics seperti BounceRates dan ExitRates, atau ProductRelated dan ProductRelated_Duration, memiliki korelasi linear yang sangat kuat ($r > 0.85$). Akibatnya, bukti probabilitas dihitung berulang kali secara berlebihan, mendistorsi probabilitas posterior ke arah kelas minoritas sehingga menghasilkan jumlah False Positive yang masif (1.225 FP pada

SMOTENC).

3. Efek Resampling SMOTENC vs RandomUnderSampler:
Pada seluruh model, RandomUnderSampler menghasilkan Recall yang lebih tinggi dibandingkan SMOTENC karena pemangkasan agresif kelas mayoritas memaksa model lebih berani menebak True. Namun, hal tersebut dibayar dengan penurunan Presisi dan Akurasi. Sebaliknya, SMOTENC memberikan generalisasi yang jauh lebih solid, menghasilkan F1-Score dan Akurasi tertinggi.

4. Keunggulan SVM RBF + SMOTENC:
SVM dengan kernel RBF berhasil memetakan pola interaksi non-linear dengan sangat baik berkat bantuan StandardScaler. Model ini menekan kesalahan False Positive hingga ke angka terendah (198 kasus), sehingga memperoleh Presisi tertinggi (58,05%), Akurasi tertinggi (87,46%), dan F1-Score tertinggi (64,17%) dengan tetap menjaga Recall di atas 71,73%.

8. IMPLEMENTASI DAN PENGUJIAN APLIKASI UI/UX STREAMLIT

Sesuai ketentuan tugas nomor 6, dibangun aplikasi antarmuka pengguna interaktif (UI/UX) berbasis Streamlit (file: app.py) menggunakan model terbaik terpilih, yaitu SVM RBF + SMOTENC.

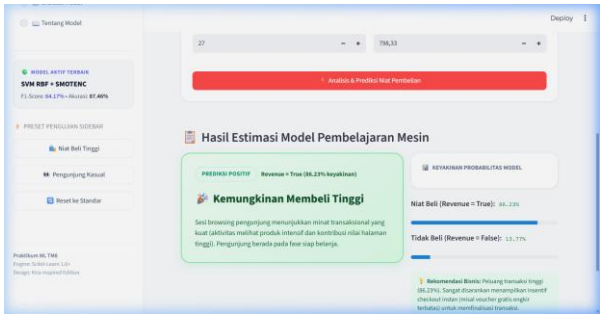
- **Arsitektur Tanpa Pelatihan Ulang (Zero-Retraining):** Model SVM dan ColumnTransformer terlatih disimpan ke dalam satu file bundel (best_model_bundle.joblib). Aplikasi memuat artefak ini menggunakan dekorator @st.cache_resource, sehingga model langsung siap melayani prediksi secara instan tanpa membebani server dengan proses pelatihan ulang.
- **Pengelompokan Formulir 17 Fitur:** Input 17 fitur dikelompokkan secara ergonomis ke dalam 3 tab (Aktivitas Halaman & Durasi, Metrik Sesi Analytics, dan Profil Pengunjung & Waktu) dengan validasi tipe data (int64, float64, string, bool) dan urutan fitur yang identik dengan dataset asli.
- **Fitur Preset Pengujian Cepat:** Disediakan tombol cepat di sidebar untuk mengisi nilai formulir secara otomatis: 'Niat Beli Tinggi' (sampel pembeli nyata) dan 'Bouncing / Kasual' (sampel pengunjung yang langsung keluar).
- **Visualisasi Keyakinan Probabilitas:** Hasil prediksi dilengkapi dengan badge status klasifikasi berbahasa Indonesia dan progress bar visual probabilitas kelas (P(False) dan P(True)) yang dihasilkan dari metode model.predict_proba().



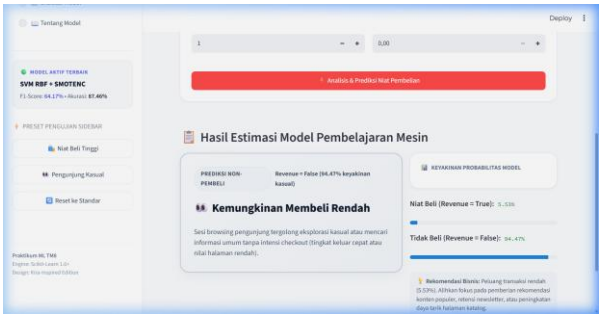
Gambar 5: Tampilan Antarmuka AI Analytics Dashboard 'Purchase Intent Analytics' (Streamlit)

Hasil Pengujian Dua Skenario Input Pengunjung

Aplikasi telah diuji menggunakan dua skenario karakteristik pengunjung yang berbeda:
• Skenario 1 (Pengunjung Berniat Beli Tinggi): Administrative=3, ProductRelated=27, Duration=798s, PageValues=22.92, BounceRates=0.0. Hasil prediksi menghasilkan status 'Berpotensi Menghasilkan Pembelian (Revenue = True)' dengan probabilitas niat beli mencapai 86,23% (P(True) = 0.862).
• Skenario 2 (Pengunjung Kasual / Langsung Keluar): Administrative=0, ProductRelated=1, Duration=0s, PageValues=0.0, BounceRates=0.20, ExitRates=0.20. Hasil prediksi menghasilkan status 'Tidak Terindikasi Menghasilkan Pembelian (Revenue = False)' dengan probabilitas tidak beli mencapai 94,47% (P(False) = 0.945).



Gambar 6a: Hasil Prediksi Skenario 1 (Niat Beli Tinggi - True: 86.23%)



Gambar 6b: Hasil Prediksi Skenario 2 (Kasual / Bouncing - False: 94.47%)

9. KESIMPULAN DAN KETERBATASAN

Berdasarkan seluruh rangkaian eksperimen dan evaluasi praktikum pertemuan 8, dapat ditarik beberapa kesimpulan pokok:

- SVM RBF + SMOTENC merupakan model terbaik secara komprehensif pada dataset Online Shoppers Purchasing Intention, dengan meraih Akurasi tertinggi (87,46%), Presisi tertinggi (58,05%), F1-Score tertinggi (64,17%), dan menekan False Positive ke angka terendah (198).
- Decision Tree + SMOTENC menempati posisi kedua yang kompetitif dengan Akurasi 86,89% dan F1-Score 63,72%, serta memiliki keunggulan waktu inferensi yang sangat cepat dan pohon keputusan yang mudah diinterpretasikan.
- Gaussian Naïve Bayes tidak cocok digunakan pada dataset web analytics ini karena asumsi independensi fitur terlanggar berat oleh adanya multikolinearitas antar fitur, menyebabkan lonjakan False Positive yang masif dan menjatuhkan Akurasi ke rentang 48% - 63%.
- SMOTENC terbukti jauh lebih unggul dan seimbang dibandingkan RandomUnderSampler karena mempertahankan seluruh informasi mayoritas asli dan hanya mensintesis sampel minoritas baru.
- Aplikasi web Streamlit berhasil mengimplementasikan inferensi model terlatih tanpa pelatihan ulang, menyediakan antarmuka 17 fitur yang terstruktur, dan memberikan prediksi probabilistik yang akurat.

Keterbatasan Eksperimen:

- Kompleksitas Komputasi SVM: Waktu pelatihan SVM RBF bertambah secara kuadratik terhadap jumlah data resample (16.476 baris), sehingga untuk dataset skala jutaan baris diperlukan metode aproksimasi linear atau subsampling.
- Representasi Kategorikal Numerik: Fitur OperatingSystems, Browser, Region, dan TrafficType pada baseline UTS diproses sebagai numerik. Pada pengembangan lebih lanjut, penerapan embedding atau grouping kategori berfrekuensi rendah dapat diuji untuk mengeksplorasi potensi peningkatan akurasi.

10. PETUNJUK MENJALANKAN PROGRAM DAN STRUKTUR FILE

A. Instalasi Dependensi:
Pastikan modul Python yang dibutuhkan telah terpasang dengan perintah:

```
pip install -r requirements.txt
```

B. Menjalankan Eksperimen Pelatihan & Komparasi:
Untuk mengeksekusi pipeline 6 eksperimen dan menghasilkan tabel serta grafik:

```
python src/main.py
```

C. Menjalankan Aplikasi Antarmuka Streamlit:
Untuk membuka aplikasi web pada browser lokal di http://localhost:8501:

```
streamlit run app.py
```

D. Struktur Berkas yang Dikumpulkan:

```
praktikum_ml_tm8/
├── dataset/
│   └── online_shoppers_intention.csv
├── outputs/
│   ├── figures/ (cm_*.png, dist_*.png, perbandingan_metrik.png)
│   ├── models/ (best_model_bundle.joblib)
│   ├── screenshots/ (ui_halaman_utama.png, ui_prediksi_*.png)
│   └── tables/ (evaluasi_model_komparasi.csv)
├── src/
│   ├── data_preprocessing.py
│   ├── data_transformation.py
│   ├── imbalanced_data.py
│   ├── decision_tree.py
│   ├── naive_bayes.py
│   ├── svm.py
│   ├── evaluation.py
│   └── main.py
├── app.py
├── requirements.txt
├── README.md
├── Laporan_Praktikum_Pertemuan_8.docx
└── Laporan_Praktikum_Pertemuan_8.pdf
```